Avaliação de Modelos de Síntese de Fala Conversacional em Português do Brasil

Antonio Moreira
Orientadora: Sandra M. Aluísio

ICMC - USP

9 de outubro de 2026

ICMC USP SÃO CARLOS

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

Prosódia

Definição de Prosódia

Prosódia é o estudo dos aspectos **entoacionais**, **rítmicos** e **enfáticos** da linguagem [11].

> *(…) o estudo da prosódia não considera diretamente o conteúdo segmental, ou **o que se diz**, e sim a forma sonora e sua função ligadas ao **como se diz**. (Barbosa:20 [5])*

A prosódia tem seu campo de estudo nos domínios **linguístico**, **paralinguístico** e **extralinguístico**.



Prosódia

Definição de Prosódia

Prosódia é o estudo dos aspectos **entoacionais**, **rítmicos** e **enfáticos** da linguagem [11].

> *(...) o estudo da prosódia não considera diretamente o conteúdo segmental, ou **o que se diz**, e sim a forma sonora e sua função ligadas ao **como se diz**. (Barbosa:20 [5])*

A prosódia tem seu campo de estudo nos domínios **linguístico**, **paralinguístico** e **extralinguístico**.

Prosódia

Definição de Prosódia

Prosódia é o estudo dos aspectos **entoacionais**, **rítmicos** e **enfáticos** da linguagem [11].

> *(...) o estudo da prosódia não considera diretamente o conteúdo segmental, ou **o que se diz**, e sim a forma sonora e sua função ligadas ao **como se diz**. (Barbosa:20 [5])*

A prosódia tem seu campo de estudo nos domínios **linguístico**, **paralinguístico** e **extralinguístico**.



Prosódia

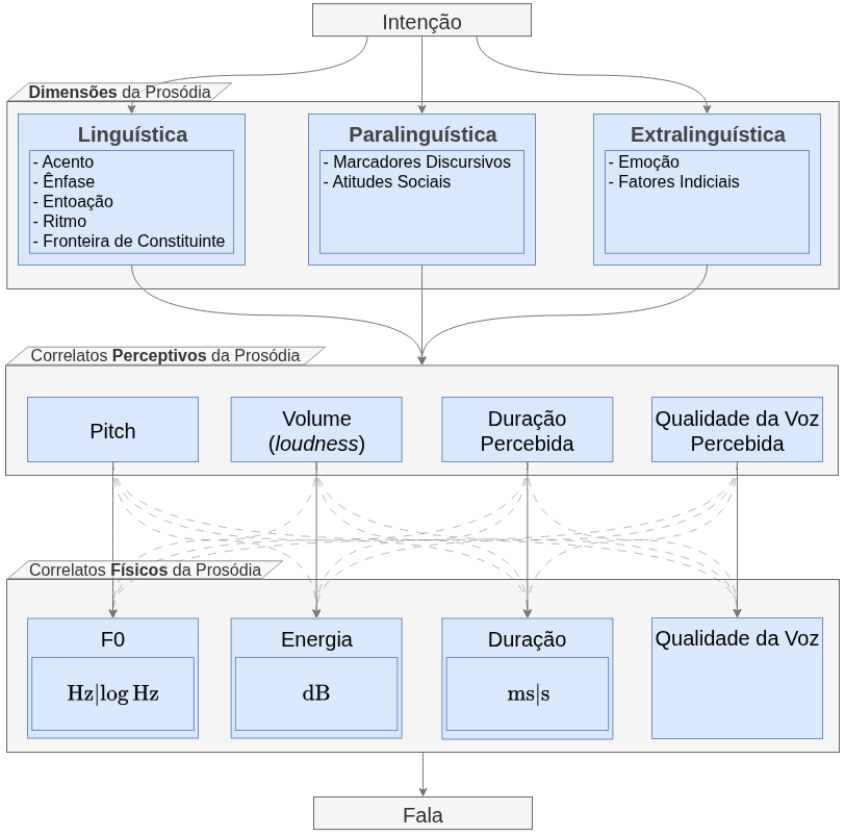


Figura: Fluxo *top-down* da materialização da fala, desde a cognição (**intenção**) até a materialidade (**o som/fala**) [5][6].
Fonte: Elaborada pelo autor.

USP SÃO CARLOS

Prosódia

- Fonologia $\rightarrow$ fonema.
- Morfologia $\rightarrow$ morfema.
- Prosódia $\rightarrow$ ...

Prosódia

*A prosódia é o componente de nossa fala que **organiza** nossos enunciados, moldando nossa maneira de falar através do concurso de modificações articulatórias que se manifestam acusticamente em **unidades prosódicas**. (Barbosa (2019). Prosódia:37 [5])*

Prosódia

Organização Hierárquica [5]

1. Sílaba
2. Pé
3. Palavra fonológica/prosódica
4. Unidade entoacional
5. Enunciado

Prosódia e Discurso

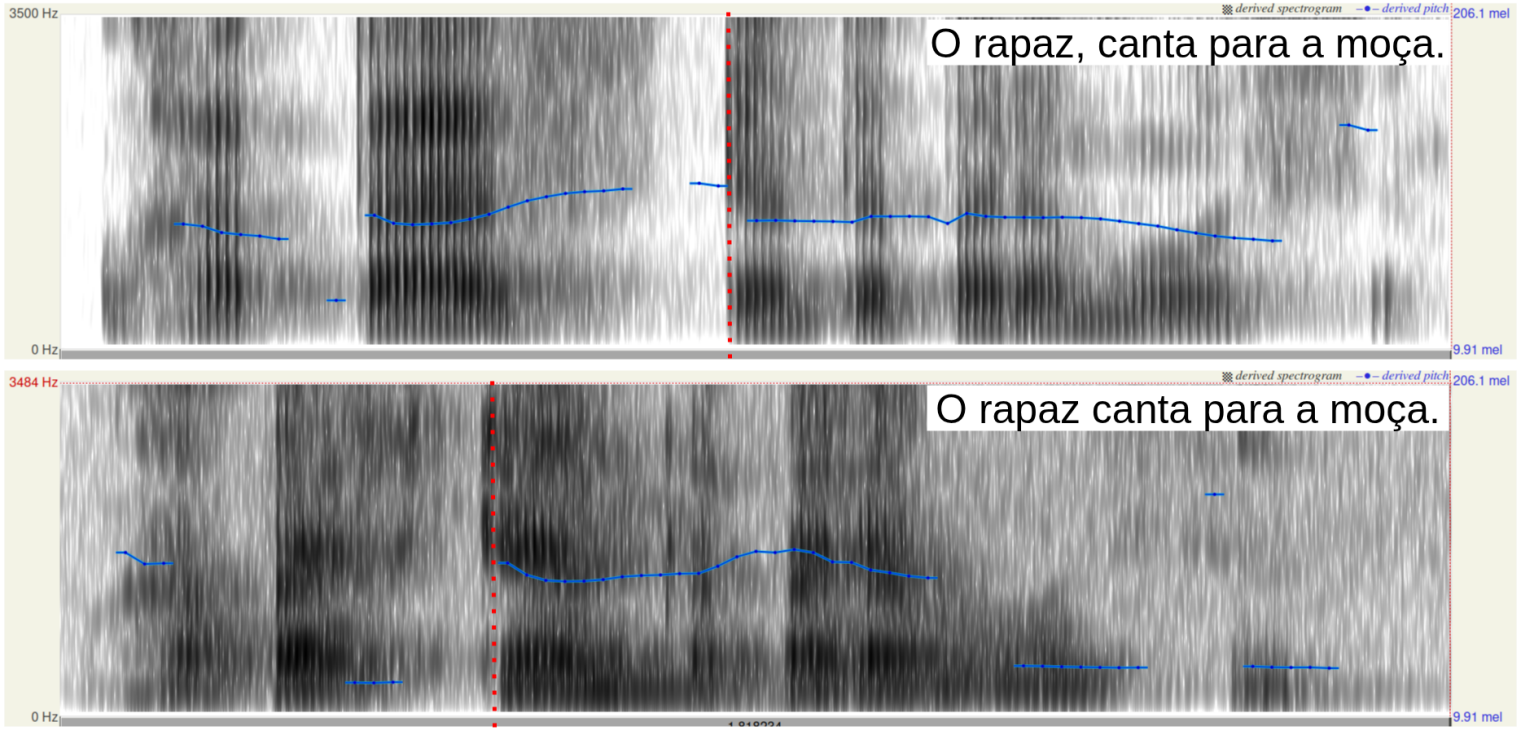


Figura: **Unidade Entoacional**: fronteira terminal.

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

Turnos

Diálogo como sequência de turnos.

Um diálogo $\mathcal{D}$ é uma sequência de n turnos [11]

$$\mathcal{D} = (t_0, t_1, \ldots, t_{n-1})$$

Cada turno t_i pertence a um falante, de modo que turnos adjacentes pertencem a falantes diferentes.

$$t_i \in \mathbb{S}_k \implies (t_{i-1}, t_{i+1}) \notin \mathbb{S}_k$$

$\mathbb{S}_k$ é o conjunto de turnos do falante k.

Atos de Fala

Cada enunciado (*utterance*) num diálogo pode ser visto como uma **ação** sendo performada pelo falante.

Taxonomia dos Atos

Não existe uma única maneira de classificar os **atos de fala**.
A classificação a seguir está no livro *Speech Acts: An Essay in the Philosophy of Language. Searle, J. R. (1969)*[16].

- Requisição
- Afirmação
- Questionamento
- Agradecimento
- Aconselhamento
- Aconselhamento
- Saudação
- Parabenização

Grounding

Os atos da fala não agem de maneira independente; pelo contrário, são uma **tarefa coletiva** [11].

Desta forma, os participantes do diálogo buscam uma **base de entendimento comum** (*grounding*) na qual todos concordam, e o diálogo constrói-se a partir daí [11].

Grounding

Contribuição

Cada ato de fala adjacente constitui uma **contribuição** [8].
Cada contribuição tem duas fases:

- **Apresentação**: O falante $\mathbb{S}_A$ apresenta o enunciado u sob a suposição de que, se o ouvinte $\mathbb{S}_B$ fornecer evidência e, ele poderá acreditar que u foi compreendido.
- **Aceitação**: O ouvinte $\mathbb{S}_B$ aceita u fornecendo a evidência e' *do que ele acredita* que entendeu. Ele o faz assumindo que, uma vez que $\mathbb{S}_A$ registra a evidência e', ele acredita que foi compreendido.

As fases da contribuição, de **forma cíclica**, constituem o entendimento mútuo (*grounding*).

Grounding

Contribuição

Cada ato de fala adjacente constitui uma **contribuição** [8].
Cada contribuição tem duas fases:

- **Apresentação**: O falante $\mathbb{S}_A$ apresenta o enunciado u sob a suposição de que, se o ouvinte $\mathbb{S}_B$ fornecer evidência e, ele poderá acreditar que u foi compreendido.
- **Aceitação**: O ouvinte $\mathbb{S}_B$ aceita u fornecendo a evidência e' *do que ele acredita* que entendeu. Ele o faz assumindo que, uma vez que $\mathbb{S}_A$ registra a evidência e', ele acredita que foi compreendido.

As fases da contribuição, de **forma cíclica**, constituem o entendimento mútuo (*grounding*).



Grounding

Evidências de Entendimento

Evidências de entendimento[8] ordenadas das mais fracas para as mais fortes:

1. **Atenção Continuada** (*Continued Attention*).
2. **Próxima Contribuição Relevante** (*Relevant Next Contribution*).
3. **Reconhecimento/Sinais** (*Acknowledgement*) – pausas-preenchidas (*filling-gaps*).
4. **Demonstração/Paráfrase** (*Demonstration*).
5. **Exibição/Repetição literal** (*Display*).

Estrutura do Diálogo

- **Subdiálogo**: **estrutura local** entre atos de fala.
- **Diálogo**

Correlaciona-se com o entendimento de *coerência local* e *coerência global* [11].

Estrutura do Diálogo

- **Subdiálogo**: **estrutura local** entre atos de fala.
- **Diálogo**

Correlaciona-se com o entendimento de *coerência local* e *coerência global* [11].

Iniciativa

Às vezes uma conversa é completamente controlada por um único participante, como no caso de **entrevistas**.

Iniciativa

O conceito de iniciativa (*conversational initiative*) refere-se ao **controle** e ao **direcionamento** do fluxo de uma conversa. Em termos simples, ter a iniciativa significa ser quem está *conduzindo* o diálogo naquele momento – seja fazendo as perguntas, introduzindo novos tópicos ou exigindo uma resposta da outra parte [11].

Iniciativa

Às vezes uma conversa é completamente controlada por um único participante, como no caso de **entrevistas**.

Iniciativa

O conceito de iniciativa (*conversational initiative*) refere-se ao **controle** e ao **direcionamento** do fluxo de uma conversa. Em termos simples, ter a iniciativa significa ser quem está *conduzindo* o diálogo naquele momento – seja fazendo as perguntas, introduzindo novos tópicos ou exigindo uma resposta da outra parte [11].

Prosódia e Discurso

- Prosódia e discurso são intimamente relacionados.
- É através da **análise prosódica** que identificamos as características intrínsecas ao diálogo...

Prosódia e Discurso

- Prosódia e discurso são intimamente relacionados.
- É através da **análise prosódica** que identificamos as características intrínsecas ao diálogo...

Prosódia e Discurso

Definição

Tomada de turno (*turn-taking*) refere-se ao sistema de sinalizações e regras que permitem aos falantes alternarem quem está falando de forma fluida e organizada [6] [5].

Prosódia e Discurso

Tomada de Turno **Cooperativa**

Acontece quando as regras de passagem de turno são respeitadas – ao final de uma interrogação, por exemplo. Neste cenário, **unidades prosódicas** específicas sinalizam que o primeiro interlocutor acabou seu turno e está passando a vez para o segundo interlocutor.

Prosódia e Discurso

Tomada de Turno **Competitiva**

Acontece quando as regras de passagem de turno não são respeitadas, como em casos de **interrupções**. Neste cenário, um interlocutor, diferente do que está falado (i.e. do que *detém* o turno), utiliza de artifícios prosódicos (e.g. aumenta a intensidade da fala), para roubar o turno.

Prosódia e Discurso

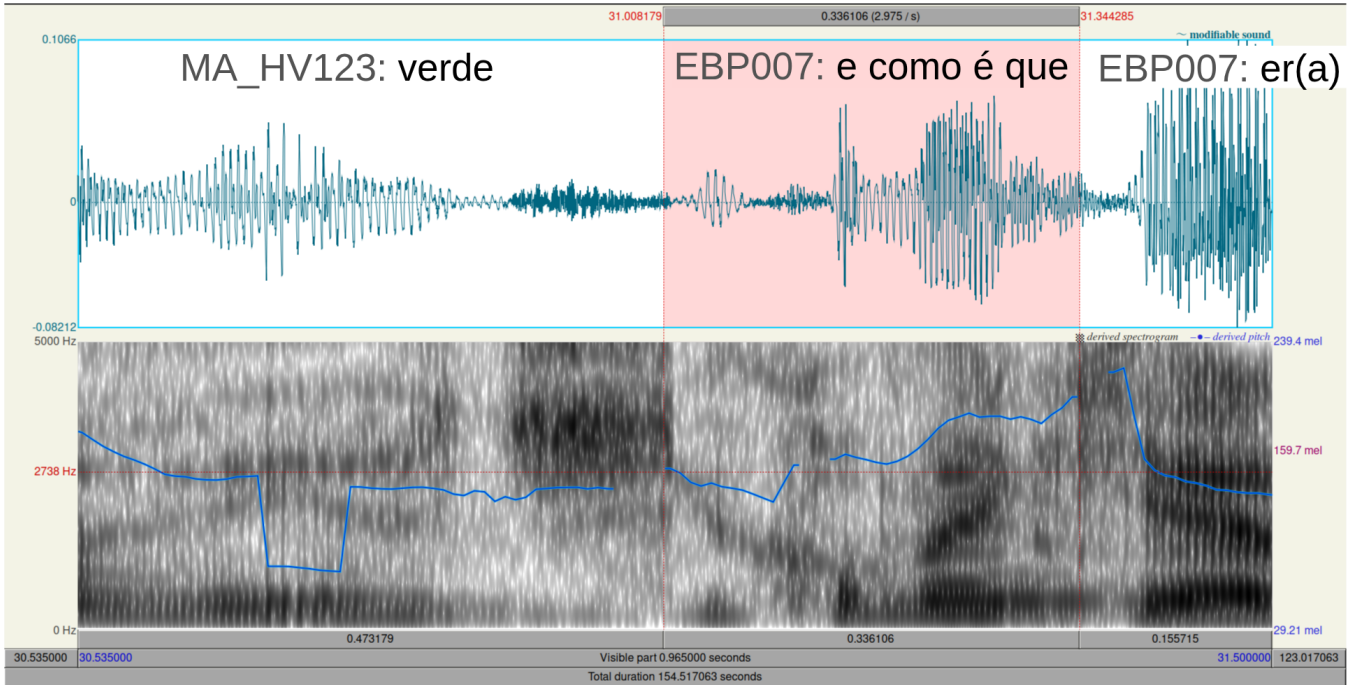


Figura: Espectrograma demonstrando a tomada de turno em um segmento do MuPeTalk.

Prosódia e Discurso

A prosódia direciona diferentes **ilocuções**, i.e., a intenção da ação na fala: uma ordem, uma dúvida, um convite, um chamado, etc.

Definição

Formas Prosódicas são as configurações acústico-articulatórias dinâmicas e contínuas que constituem a materialização física da prosódia em um enunciado [5].

Prosódia e Discurso

A prosódia direciona diferentes **ilocuções**, i.e., a intenção da ação na fala: uma ordem, uma dúvida, um convite, um chamado, etc.

Definição

Formas Prosódicas são as configurações acústico-articulatórias dinâmicas e contínuas que constituem a materialização física da prosódia em um enunciado [5].

Prosódia e Discurso

Entrainment Prosódico

Definido pela capacidade dos seres humanos se ajustarem, tanto em nível comportamental como discursivo, ao seu interlocutor [7].

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

Tipos de modelos de *TTS*

Controlabilidade

Capacidade de um modelo de síntese de fala de **controlar explicitamente** os correlatos físicos ou perceptivos da prosódia [18].

Desta forma:

- **Modelos Não-Controláveis**: não contêm estruturas dedicadas à controlar atributos fonéticos.
- **Modelos Controláveis**: contêm estruturas dedicadas à controlar atributos prosódicos.

Tipos de modelos de *TTS*

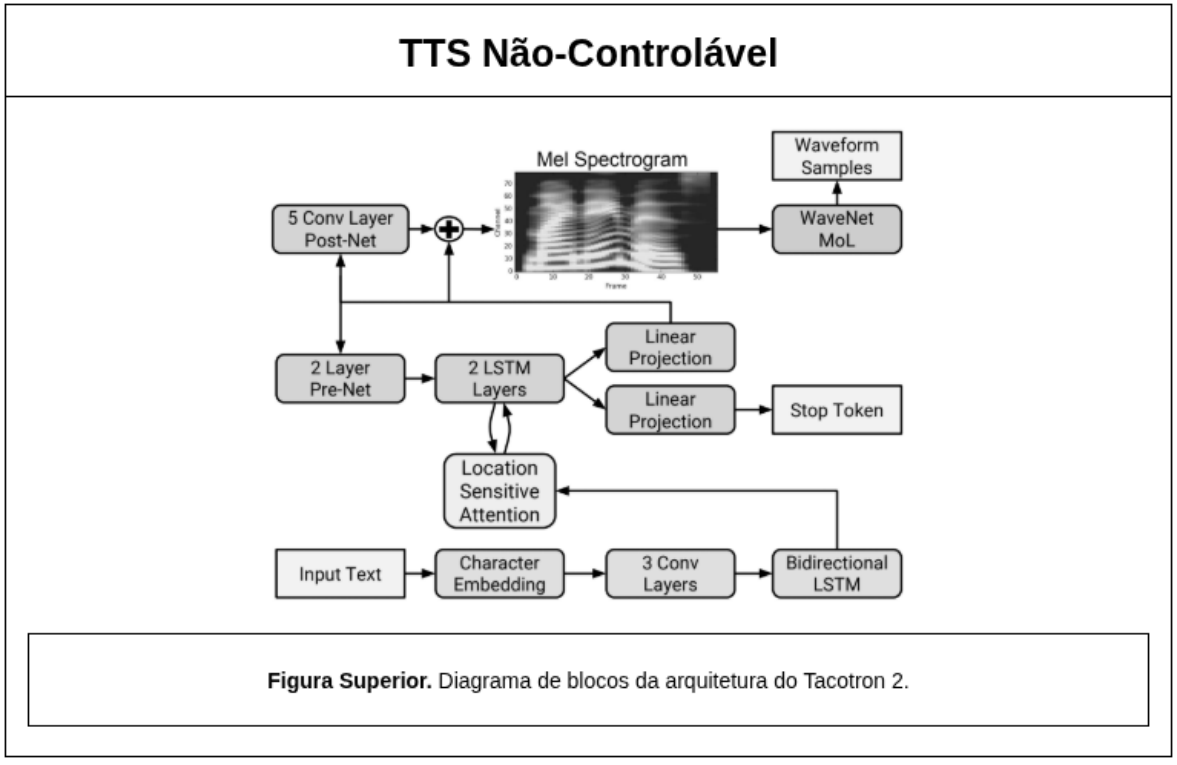


Figura: Arquitetura do *Tacotron2*, modelo autorregressivo (*AR*) baseado em *RNN* – Adaptado de [17].

Tipos de modelos de *TTS*

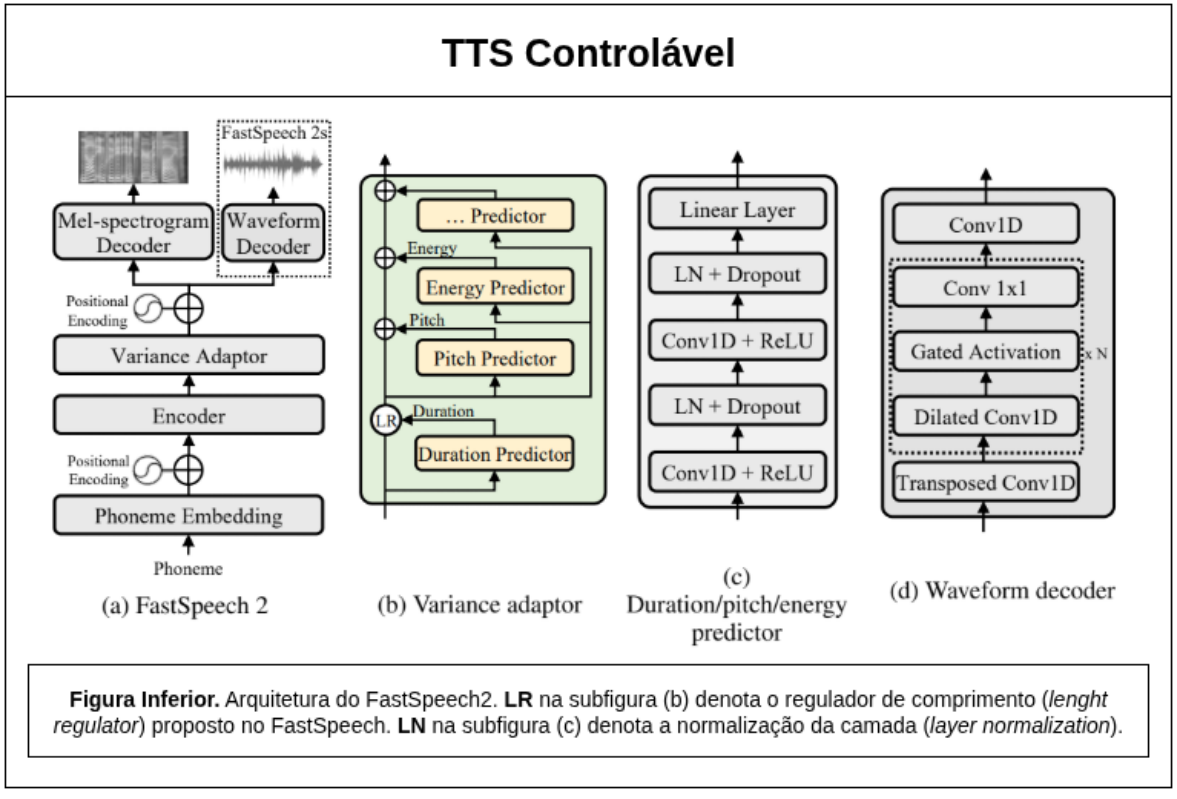


Figura Inferior. Arquitetura do FastSpeech2. **LR** na subfigura (b) denota o regulador de comprimento (*lenght regulator*) proposto no FastSpeech. **LN** na subfigura (c) denota a normalização da camada (*layer normalization*).

Figura: *FastSpeech2* (*NAR*) baseado em *Transformer* – Adaptado de [15].

Tipos de modelos de *TTS*

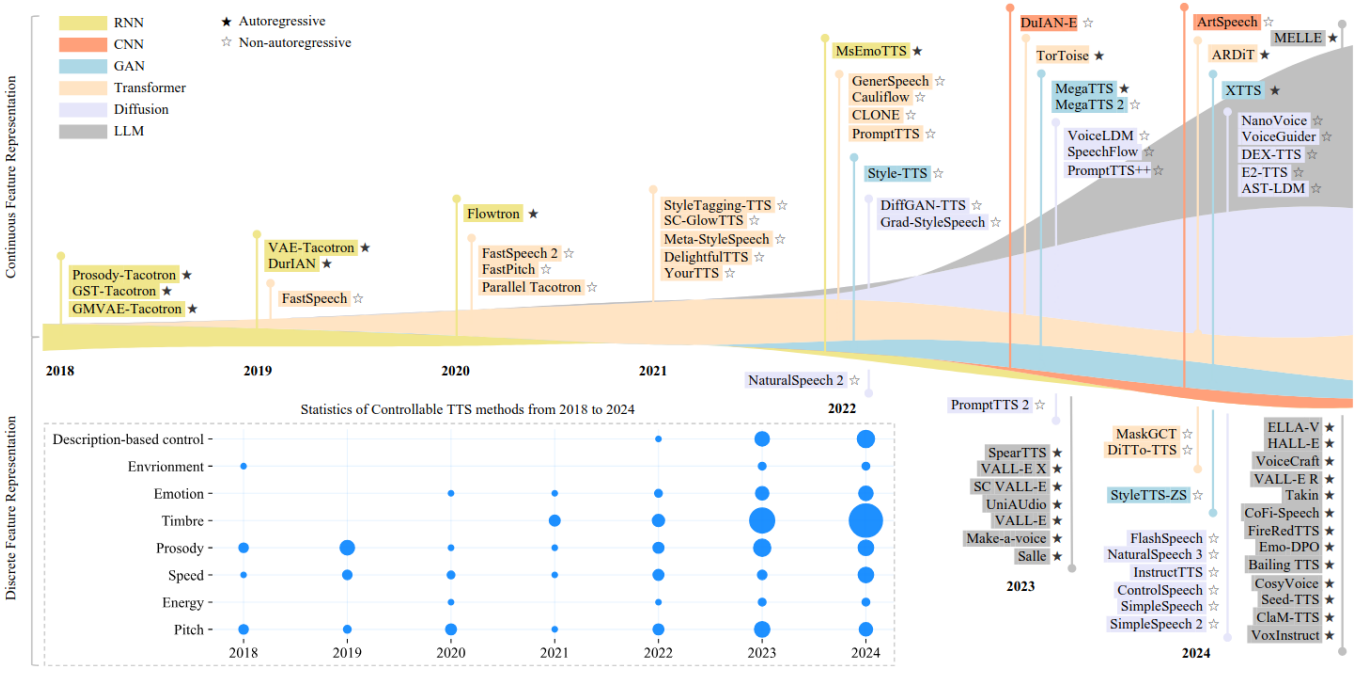


Figura: Tendência observada da predominância de modelos baseados em **Difusão** e **LLM** [18]

.

Tipos de modelos de *TTS*

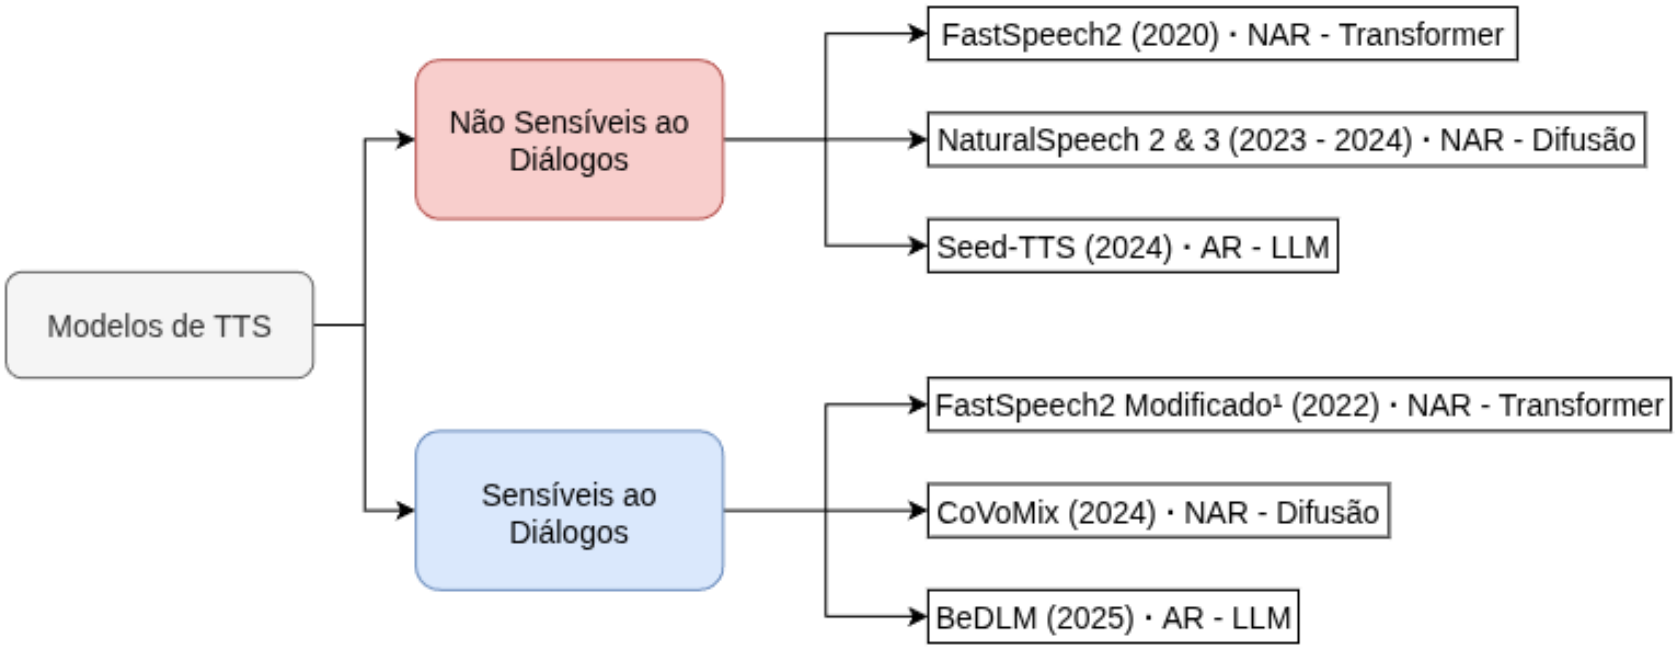


Figura: Classificação de modelos de TTS quanto ao suporte **nativo** ao diálogo. Fonte: Elaborada pelo autor.

Tipos de modelos de *TTS*

Os modelos de síntese de fala ainda enfrentam problemas para lidar com a síntese de diálogos [13].

Dentre os modelos sensíveis ao diálogo, nem todas as **características intrínsecas ao diálogo** são capturadas.

Métricas de Avaliação de Áudios Sintetizados

Métricas Subjetivas

A **avaliação subjetiva** refere-se a configurações de avaliação nas quais *humanos* medem ou quantificam o desempenho e a qualidade [2].

Métricas Objetivas

A **avaliação objetiva** avalia quantitativamente propriedades acústicas, inteligibilidade e similaridade de forma objetiva, sem intervenção de ouvintes humanos [2].

Métricas de Avaliação de Áudios Sintetizados

MOS

MOS (*Mean Opinion Score*): Mede a qualidade geral e a naturalidade intrínseca da voz em uma escala absoluta. É a métrica mais frequente em avaliações subjetivas [10].

Métricas de Avaliação de Áudios Sintetizados

CMOS

CMOS (Comparative Mean Opinion Score): Avalia a preferência e a qualidade de forma comparativa entre duas amostras de fala [10].

Métricas de Avaliação de Áudios Sintetizados

EyeTracking-MOS

Evolução moderna do *MOS* tradicional [1].

- Maior “assertividade” na pontuação devido ao rastreamento ocular.
- Aumento significativo na escala do resultado obtido (de $[1 \rightarrow 5]$ para $[0 \rightarrow 100]$).

Métricas de Avaliação de Áudios Sintetizados

WER e CER

WER (*Word Error Rate*) e **CER** (*Character Error Rate*): Medem a inteligibilidade do áudio sintetizado, submetendo-o a um modelo *ASR* e calculando a taxa de erro de palavras e caracteres [11].
Fórmula:

$$WER = \frac{S + D + I}{N}$$

Onde S representa as substituições, D as deleções, I as inserções e N o número total de palavras (ou caracteres, no caso do CER) presentes na referência.

Métricas de Avaliação de Áudios Sintetizados

F0-RMSE

F0 RMSE (Raiz do Erro Quadrático Médio da Frequência Fundamental): Avalia a precisão do *pitch* e a fidelidade acústica da prosódia. É a métrica objetiva mais utilizada na literatura [10].
Fórmula:

$$RMSE_{F0} = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(F0_t - \hat{F0}_t)^2}$$

Em que T é o número total de quadros, $F0_t$ é a frequência fundamental de referência e $\hat{F0}_t$ é a frequência fundamental estimada no quadro t.

Métricas de Avaliação de Áudios Sintetizados

TTSDS2- ICLR 2026

TTSDS2 (*Text-to-Speech Distribution Score 2*) [14] é uma métrica objetiva, distribucional e multifatorial proposta para avaliar sistemas de TTS (*Text-to-Speech*), comparando distribuições de atributos perceptuais da fala sintética com a fala real e com distribuições de ruído.

Métricas de Avaliação de Áudios Sintetizados

TTSDS2

Fatores:

- **Genérico** (*generic*)
- **Falante** (*speaker*)
- **Prosódia** (prosody)
- **Inteligibilidade** (*intelligibility*)

Cálculo da métrica:

$$\text{TTSDS2}(D, \tilde{D}, \mathfrak{D}^{\text{NOISE}}) = 100 \times \frac{W_2^{\text{NOISE}}}{W_2^{\text{REAL}} + W_2^{\text{NOISE}}}$$

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

DailyTalk – ICASSP 2023

Contribuições

1. *Córpus* conversacional aberto para treinamento de modelos de síntese de fala conversacional;
2. Proposta de modelo de síntese de fala conversacional sensível ao contexto;
3. Métricas de avaliação de diálogos sintetizados por modelos de *TTS*.

DailyTalk – ICASSP 2023

1. Obtenção e Estruturação do *córpus*.
2. Modelo *baseline* (**FastSpeech2** [15] Modificado)
3. Experimentos: integridade e adaptabilidade.
4. Métricas:
   - *Dialogue-level MOS*
   - *Pairwise MOS* (GT-synthesized)
   - *Pairwise MOS* (synthesized pair)
   - *User-system Simulation MOS*

DailyTalk – ICASSP 2023

1. Obtenção e Estruturação do *córpus*.
2. Modelo *baseline* (**FastSpeech2** [15] Modificado)
3. Experimentos: integridade e adaptabilidade.
4. Métricas:
   - *Dialogue-level MOS*
   - *Pairwise MOS* (GT-synthesized)
   - *Pairwise MOS* (synthesized pair)
   - *User-system Simulation MOS*

DailyTalk – ICASSP 2023

1. Obtenção e Estruturação do *córpus*.
2. Modelo *baseline* (**FastSpeech2** [15] Modificado)
3. Experimentos: integridade e adaptabilidade.
4. Métricas:
   - *Dialogue-level MOS*
   - *Pairwise MOS* (GT-synthesized)
   - *Pairwise MOS* (synthesized pair)
   - *User-system Simulation MOS*

DailyTalk – ICASSP 2023

1. Obtenção e Estruturação do *córpus*.
2. Modelo *baseline* (**FastSpeech2** [15] Modificado)
3. Experimentos: integridade e adaptabilidade.
4. Métricas:
   - *Dialogue-level MOS*
   - *Pairwise MOS* (GT-synthesized)
   - *Pairwise MOS* (synthesized pair)
   - *User-system Simulation MOS*

DailyTalk – ICASSP 2023

DailyTalk Estatísticas

	DailyTalk
Duração Total	$\approx$ 20 horas
Número de Locutores	2 (1 Masc., 1 Fem.)
Número de Enunciados	23.773
Gênero Textual	Diálogos
Estilo	Fala Conversacional (espontânea)

MagicData-RAMC – Interspeech 2022

Contribuições

RAMC = Rich Annotated Mandarin Conversational (speech dataset).

1. *Córpus* conversacional especializado no cenário de diálogos;
2. Detalhamento dos metadados dos falantes.

MagicData-RAMC – Interspeech 2022

1. Magic Data Technology Co., Ltd: especializados na criação de conjuntos de dados.
2. Diálogos do cotidiano (devidamente rotulados).
3. Experimentos em *ASR* e *SD*.

MagicData-RAMC – Interspeech 2022

1. Magic Data Technology Co., Ltd: especializados na criação de conjuntos de dados.
2. Diálogos do cotidiano (devidamente rotulados).
3. Experimentos em *ASR* e *SD*.

MagicData-RAMC – Interspeech 2022

1. Magic Data Technology Co., Ltd: especializados na criação de conjuntos de dados.
2. Diálogos do cotidiano (devidamente rotulados).
3. Experimentos em *ASR* e *SD*.

MagicData-RAMC – Interspeech 2022

MagicData-RAMC Estatísticas

	MagicData
Duração Total	$\approx$ 180 horas
Número de Locutores	663 (368 Masc., 295 Fem.)
Número de Domínios	15
Gênero Textual	Diálogos
Estilo	Fala Conversacional (espontânea)

Taskmaster – EMNLP 2019

Contribuições

1. *Córpus* conversacional textual.
2. Técnica de obtenção de *córpus*.

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

MuPe – COLING 2025

Contribuições

1. *Córpus* conversacional no domínio de **entrevista**.

MuPe – COLING 2025

1. Obtenção:
   - Cedido pelo Museu da Pessoa.
2. Características:
   - Segmentados pelo *WhisperX* [3]
   - Anonimizado (principalmente no início)

MuPe – COLING 2025

1. Obtenção:
   - Cedido pelo Museu da Pessoa.
2. Características:
   - Segmentados pelo *WhisperX* [3]
   - Anonimizado (principalmente no início)

MuPe – COLING 2025

	MuPe
Duração Total	$\approx$ 365 horas
Número de Locutores	249 (114 Masc., 135 Fem.)
Gênero Textual	Diálogos
Estilo	Fala Conversacional (espontânea)

Lacunas

O fluxo de pesquisa de modelos – do treinamento à avaliação – de *TTS* conversacionais necessita de *corpora* conversacionais abertos e devidamente anotados.

Escassez de Córpus

Observa-se, mesmo no inglês, poucos conjuntos de dados com tais características [12] [13] [18].

Lacunas

O fluxo de pesquisa de modelos – do treinamento à avaliação – de *TTS* conversacionais necessita de *corpora* conversacionais abertos e devidamente anotados.

Escassez de Córpus

Observa-se, mesmo no inglês, poucos conjuntos de dados com tais características [12] [13] [18].

Lacunas

TABLE V
A SUMMARY OF OPEN-SOURCE DATASETS FOR CONTROLLABLE TTS.

Dataset	Hours	#Speakers	Labels											Lang	Release Time
			Pit.	Ene.	Spe.	Age	Gen.	Emo.	Emp.	Acc.	Top.	Des.	Env.	Dia.		
Taskmaster-1 [254]	/	/												✓	en	2019.09
Libri-light [255]	60,000	9,722									✓				en	2019.12
AISHELL-3 [256]	85	218				✓	✓			✓					zh	2020.10
ESD [257]	29	10						✓							en,zh	2021.05
GigaSpeech [258]	10,000	/									✓				en	2021.06
WenetSpeech [259]	10,000	/									✓				zh	2021.07
PromptSpeech [101]	/	/	✓	✓	✓			✓				✓			en	2022.11
DailyTalk [260]	20	2						✓			✓			✓	en	2023.05
TextrolSpeech [247]	330	1,324	✓	✓	✓		✓	✓				✓			en	2023.08
VoiceLDM [231]	/	/	✓				✓	✓				✓	✓		en	2023.09
VccmDataset [106]	330	1,324	✓	✓	✓		✓	✓				✓			en	2024.06
MSceneSpeech [261]	13	13									✓				zh	2024.07
SpeechCraft [262]	2,391	3,200	✓	✓	✓	✓	✓	✓	✓		✓	✓			en,zh	2024.08

Abbreviations: Pit(ch), Ene(rgy)=volume=loudness, Spe(ed)=duration, Gen(der), Emo(tion), Emp(hasis), Acc(ent), Dia(logue), Env(ironment), Des(cription).

Figura: Tabela que sumariza *córpora* conversacionais para TTSs controláveis. Fonte: [18].

Lacunas

Escassez de Córpus

- Lee, Kim e Kim (2025). “Behavior-SD: Behaviorally Aware Spoken Dialogue Generation with Large Language Models” [13].
  - *Behavior-SD*: córpus.

Lacunas

- Zhang et al. (2024). “CoVoMix: advancing zero-shot speech generation for human-like multi-talker conversations” [21].
  - *Turn-Taking*.
  - Comportamentos paralinguísticos.
  - Consistência
- Lee, Kim e Kim (2025). “Behavior-SD: Behaviorally Aware Spoken Dialogue Generation with Large Language Models” [13].
  - *BeDLM*: *Behavior-conditioned spoken Dialogue Language Model*.

Lacunas

1. Poucas métricas para Avaliação de Diálogos Sintetizados.
   - Galdino et al. (2025). “The evaluation of prosody in speech synthesis: a systematic review” [10]
   - Xu et al. (2026). “Conversational Speech Naturalness Predictor” [19]
   - Lee, Kim e Kim (2025). “Behavior-SD: Behaviorally Aware Spoken Dialogue Generation with Large Language Models” [13]
   - Yang et al. (2026). “Position: Towards Responsible Evaluation for Text-to-Speech” [20]
2. Dentre as métricas que existem, **não existe um consenso**.

Lacunas

Ausência de um *framework* consolidado para adaptação de conjuntos de dados:

- Bakhturina, Lavrukhin e Ginsburg (2022). “A Toolbox for Construction and Analysis of Speech Datasets” [4]

Objetivo Geral

Criação de um *framework* completo que seja capaz de estruturar conjuntos de dados conversacionais novos e já existentes afim de adequá-los à tarefa de treinamento de *TTS* conversacionais *SOTA* específicos e, em seguida, avaliar o desempenho desses novos conjuntos de dados sob a ótica de métricas dedicadas ao contexto conversacional.

Objetivos Específicos

1. Adaptar o conjunto de dados MuPe[9] à tarefa de *TTS* conversacional e avalia-lo no modelo proposto.
2. Criação de um pipeline para adequar um conjunto de dados de fala editada (dados do *PECEGE*) à tarefa de treinamento de modelos de *TTS* conversacionais.

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

ICMC USP SÃO CARLOS

DiaTTS-Toolkit

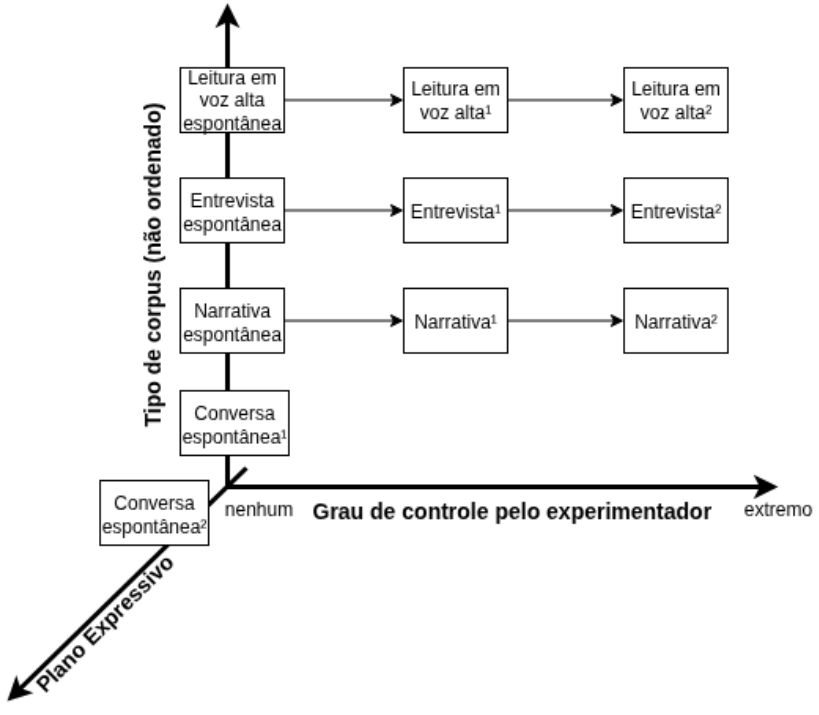


Figura: Classificação de *córpora* segundo: grau de controle pelo experimentado; gênero enunciativo ; plano expressivo. Fonte: Adaptado de Barbosa [6].

USP SÃO CARLOS

DiaTTS-Toolkit

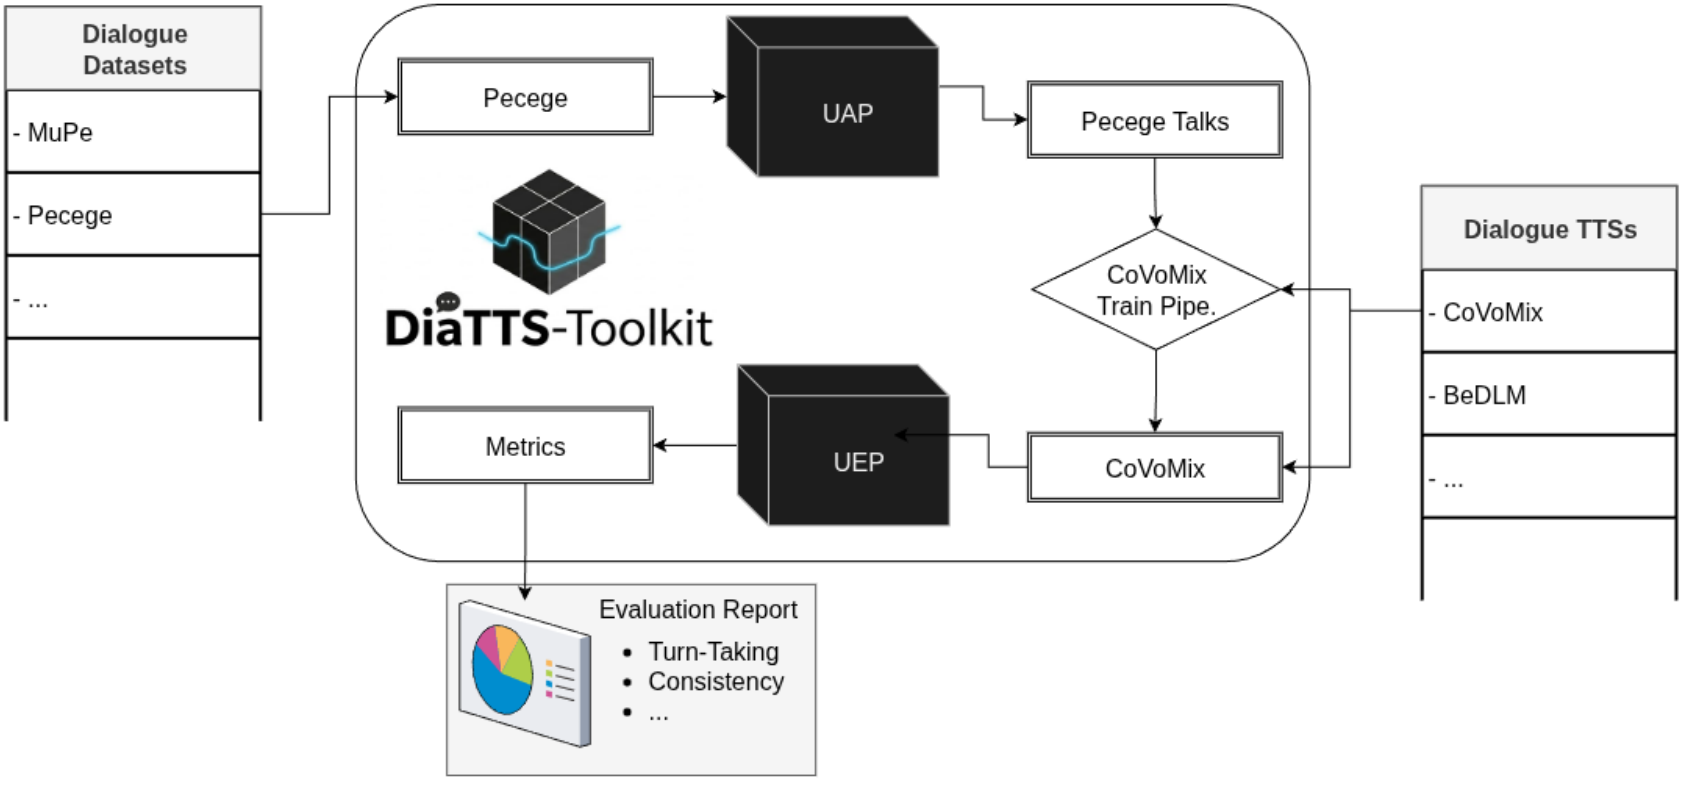


Figura: Esquemático *DiaTTS-Toolkit*. Fonte: Elaborada pelo autor.

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

MuPeTalk

Pipeline de Criação

1. Restrições do DailyTalk.
   - $5+$ diálogos;
   - Alternância de sexo;
2. Restrição Adicional:
   - Geográfica: Entrevistas *apenas* de São Paulo capital;
3. Inferência do sexo dos entrevistadores via Gemini API

MuPeTalk

Pipeline de Criação

1. Restrições do DailyTalk.
   - $5+$ diálogos;
   - Alternância de sexo;
2. Restrição Adicional:
   - Geográfica: Entrevistas *apenas* de São Paulo capital;
3. Inferência do sexo dos entrevistadores via Gemini API

MuPeTalk

Pipeline de Criação

1. Restrições do DailyTalk.
   - $5+$ diálogos;
   - Alternância de sexo;
2. Restrição Adicional:
   - Geográfica: Entrevistas *apenas* de São Paulo capital;
3. Inferência do sexo dos entrevistadores via Gemini API

MuPeTalk

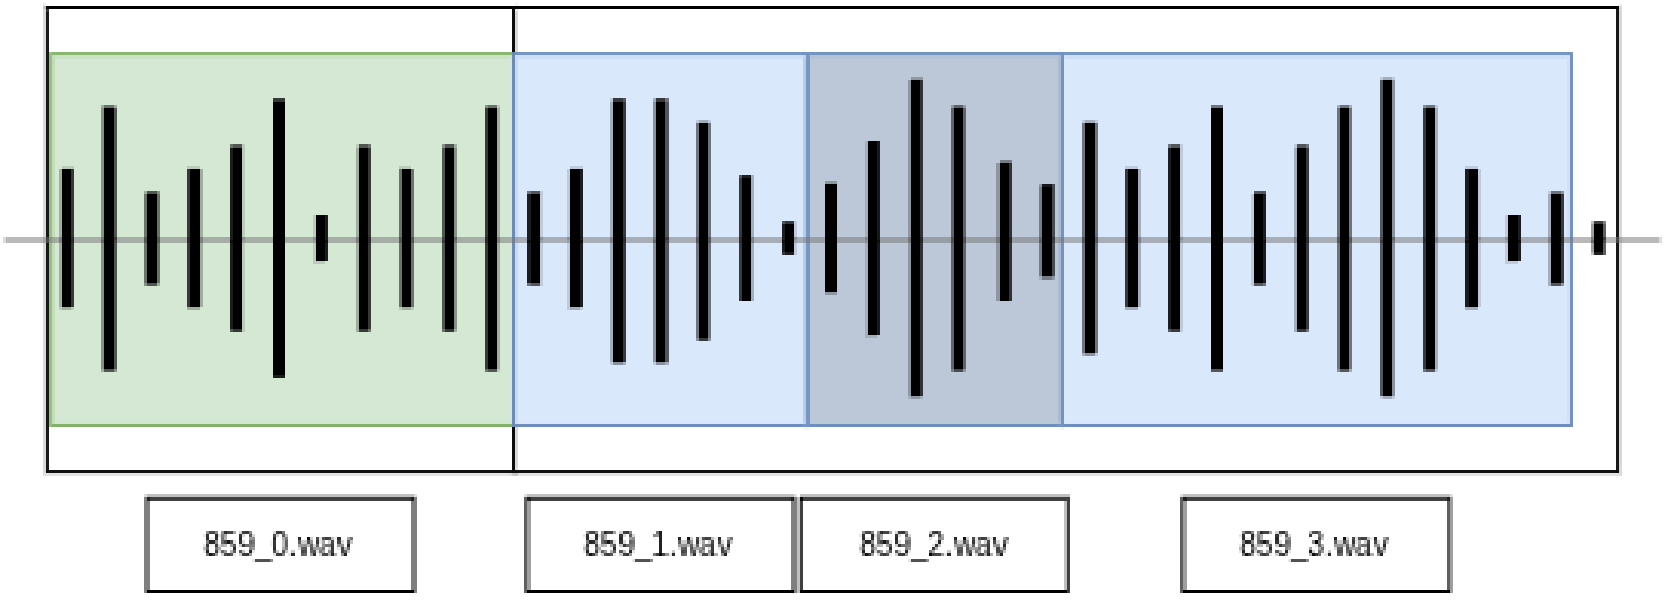


Figura: Segmentos Faltantes

Sumário

1 Fundamentação Teórica
- Prosódia
- Conversação
- Modelos de TTS

2 Revisão da Literatura
- Trabalhos sobre *corpora* conversacionais em Inglês e Chinês
- Trabalhos sobre *corpora* conversacionais em Português

3 Lacunas

4 Objetivos

5 DiaTTS-Toolkit
- Core Components
- MuPeTalk
- PecegeTalk

ICMC USP SÃO CARLOS

PecegeTalk

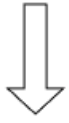
- Pecege e Skylar
- Transcrição editada vs Transcrição Literal

PecegeTalk

SRT Original

```
13
00:00:51,588 --> 00:00:56,420
Estou no Pecege há 13 anos,
desde 2010.

14
00:00:56,686 --> 00:01:01,071
Saí por um tempo, mas voltei.
Já trafeguei pelas áreas de TI,
```



SRT *"Integral"*

```
13
00:00:51,588 --> 00:00:56,420
[ÃN] Eu tô no Pecege aí... há ([DISFLUÊNCIA]) 13 anos,
mais ou menos [INTERRUPÇÃO] desde 2010.

14
00:00:56,686 --> 00:01:01,071
Saí por um tempo, mas voltei, ali.
[ÃN] Já trafeguei aí pelas áreas de TI,
```

Figura: **PecegeTalk**: Transcrição editada vs. Transcrição Literal

Cronograma

Tarefas	Ano 0 - 2024	Ano 1 - 2025			
	2º S	1º T	2º T	3º T	4º T
Créditos como Aluno Especial	X				
Créditos como Aluno Regular		X	X		
F.T. - TTS conversacional			X	X	X
F.T. - Métricas de TTS conversacional				X	X
Segmentação do MuPe para criação do MuPeTalk				X	X

Cronograma

Tarefas	**Ano 2 - 2026**			
	1º T	**2º T**	**3º T**	**4º T**
F.T. - TTS conversacionais	X	X	X	
F.T. - Métricas de TTS conversacionais	X	X	X	X
F.T. - Frameworks de criação de córpora	X	X		
F.T. - Prosódia	X	X	X	X
F.T. - Processamento de Sinais			X	X
Criação do MuPeTalk	X			
Disponibilização do MuPeTalk		X		
Treinamento usando MuPeTalk		X		
Validação dos áudios gerados		X		
Publicação do MuPeTalk		X		

Cronograma

Tarefas	Ano 2 - 2026		Ano 3 - 2027			
	3º T	4º T	1º T	2º T	3º T	4º T
ETL Pipeline PecegeTalk	X					
Re-anotação PecegeTalk	X	X				
Treinamento PecegeTalk AR/NAR		X	X			
Validação Treinamento PecegeTalk		X	X			
Publicação PecegeTalk			X			
Estruturação DiaTTS-Toolkit			X	X	X	
Publicação DiaTTS-Toolkit					X	
Defesa						X

References I

[1] Gustavo Araújo et al. “EyetrackingMOS: Proposta de um método de avaliação online para modelos de síntese de fala”. Em: *Anais do XV Simpósio Brasileiro de Tecnologia da Informação e da Linguagem Humana*. Belém/PA: SBC, 2024, pp. 87–96. DOI: 10.5753/stil.2024.245424. URL: https://sol.sbc.org.br/index.php/stil/article/view/31120.

[2] Tom Bäckström et al. *Introduction to Speech Processing*. 2ª ed. 2022. DOI: 10.5281/zenodo.6821775. URL: https://speechprocessingbook.aalto.fi.

[3] Max Bain et al. “WhisperX: Time-Accurate Speech Transcription of Long-Form Audio”. Em: *INTERSPEECH 2023* (2023), pp. 4489–4493. DOI: 10.21437/Interspeech.2023-78.

ICMC USP SÃO CARLOS

References II

[4] Evelina Bakhturina, Vitaly Lavrukhin e Boris Ginsburg. “A Toolbox for Construction and Analysis of Speech Datasets”. Em: arXiv:2104.04896 (jan. de 2022). arXiv:2104.04896 [eess]. DOI: 10.48550/arXiv.2104.04896. URL: http://arxiv.org/abs/2104.04896.

[5] Plinio A Barbosa. *Prosódia*. Parábola Editorial, 2019. ISBN: 8579341639.

[6] Plínio A. Barbosa. “Conhecendo melhor a prosódia: aspectos teóricos e metodológicos daquilo que molda nossa enunciação”. Em: *Revista de Estudos da Linguagem* 20.1 (jun. de 2012), pp. 11–27. ISSN: 2237-2083. DOI: 10.17851/2237-2083.20.1.11-27.

ICMC USP SÃO CARLOS

References III

[7] Vera Mónica dos Santos Cabarrão. “Entrainment in European Portuguese”. Tese de dout. Universidade de Lisboa, abr. de 2020. URL: https://repositorio.ulisboa.pt/entities/publication/9a6f3d17-efed-4212-98f6-dd96e3d029c2.

[8] Herbert H. Clark e Edward F. Schaefer. “Contributing to discourse”. Em: *Cognitive Science* 13.2 (1989), pp. 259–294. ISSN: 0364-0213. DOI: https://doi.org/10.1016/0364-0213(89)90008-6. URL: https://www.sciencedirect.com/science/article/pii/0364021389900086.

ICMC USP SÃO CARLOS

References IV

[9] Sidney Evaldo Leal et al. “MuPe Life Stories Dataset: Spontaneous Speech in Brazilian Portuguese with a Case Study Evaluation on ASR Bias against Speakers Groups and Topic Modeling”. Em: *Proceedings of the 31st International Conference on Computational Linguistics*. Ed. por Owen Rambow et al. Abu Dhabi, UAE: Association for Computational Linguistics, jan. de 2025, pp. 6076–6087. URL: https://aclanthology.org/2025.coling-main.407/.

[10] Julio Cesar Galdino et al. “The evaluation of prosody in speech synthesis: a systematic review”. Em: *Journal of the Brazilian Computer Society* 31.1 (jul. de 2025), pp. 466–487. ISSN: 1678-4804. DOI: 10.5753/jbcs.2025.5468.

ICMC USP SÃO CARLOS

References V

[11] Daniel Jurafsky e James H. Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models*. 3rd. Stanford, 2026. URL: https://web.stanford.edu/~jurafsky/slp3/.

[12] Keon Lee, Kyumin Park e Daeyoung Kim. "DailyTalk: Spoken Dialogue Dataset for Conversational Text-to-Speech". Em: *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2023, pp. 1–5. DOI: 10.1109/ICASSP49357.2023.10095751.

ICMC USP SÃO CARLOS

References VI

[13] Sehun Lee, Kang-wook Kim e Gunhee Kim. “Behavior-SD: Behaviorally Aware Spoken Dialogue Generation with Large Language Models”. Em: *Proceedings of the 2025 Conference of the Nations of the Americas Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers)*. Ed. por Luis Chiruzzo, Alan Ritter e Lu Wang. Albuquerque, New Mexico: Association for Computational Linguistics, abr. de 2025, pp. 9574–9593. ISBN: 979-8-89176-189-6. DOI: 10.18653/v1/2025.naacl-long.484. URL: https://aclanthology.org/2025.naacl-long.484/.

References VII

[14] Christoph Minixhofer, Ondřej Klejch e Peter Bell. “TTSDS2: Robust Objective Evaluation for Human-Quality Synthetic Speech”. Em: *13th edition of the Speech Synthesis Workshop*. 2025, pp. 68–75. DOI: 10.21437/SSW.2025-11.

[15] Yi Ren et al. “FastSpeech 2: Fast and High-Quality End-to-End Text to Speech”. Em: *International Conference on Learning Representations (ICLR)*. 2021. URL: https://openreview.net/forum?id=piLPYqxtWuA.

[16] John R. Searle. *Speech Acts: An Essay in the Philosophy of Language*. Cambridge University Press, 1969.

ICMC USP SÃO CARLOS

References VIII

[17] Jonathan Shen et al. *Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions*. 2018. arXiv: 1712.05884 [cs.CL]. URL: https://arxiv.org/abs/1712.05884.

[18] Tianxin Xie et al. "Towards Controllable Speech Synthesis in the Era of Large Language Models: A Systematic Survey". Em: *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing*. Ed. por Christos Christodoulopoulos et al. Suzhou, China: Association for Computational Linguistics, nov. de 2025, pp. 764–791. ISBN: 979-8-89176-332-6. DOI: 10.18653/v1/2025.emnlp-main.40. URL: https://aclanthology.org/2025.emnlp-main.40/.

References IX

[19] Anfeng Xu et al. “Conversational Speech Naturalness Predictor”. Em: arXiv:2603.01467 (mar. de 2026). arXiv:2603.01467 [eess]. DOI: 10.48550/arXiv.2603.01467. URL: http://arxiv.org/abs/2603.01467.

[20] Yifan Yang et al. “Position: Towards Responsible Evaluation for Text-to-Speech”. Em: arXiv:2510.06927 (jan. de 2026). arXiv:2510.06927 [eess]. DOI: 10.48550/arXiv.2510.06927. URL: http://arxiv.org/abs/2510.06927.

[21] Leying Zhang et al. “CoVoMix: advancing zero-shot speech generation for human-like multi-talker conversations”. Em: *Proceedings of the 38th International Conference on Neural Information Processing Systems, (NeurIPS 2024)*. NIPS ’24. Vancouver, BC, Canada: Curran Associates Inc., 2024. ISBN: 9798331314385.